台灣總統選舉縣市得票率預測：上屆結果、全國民調與政綱特徵的時間外推回測研究

Forecasting County-level DPP Vote Share in Taiwan's Presidential Elections (2000–2024):
An Out-of-Time Backtest of Persistence, Polls and Platforms

畢業專題研究報告（Final Year Project）

Jacky Wong

香港浸會大學 Hong Kong Baptist University

2026 年 10 月 27 日

本報告所有數字均取自專案輸出檔（`outputs/metrics/`、`analysis/`、`data/`）；研究定位為方法論回測，不提供勝選機率或因果結論。

摘要

台灣總統選舉每四年一次，自 2000 年起至 2024 年僅有七屆，22 個縣市的政治版圖又呈現高度持續的地理分布——這使「預測」同時變得容易（抄上屆已相當準）與困難（可供學習的屆次極少、而全國性擺盪難以從歷史資料推知）。本研究以縣市層級民進黨（DPP）總統得票率為標的，建立嚴格的時間外推（out-of-time, OOT）expanding-window 回測，比較上屆結果基準（PreviousElectionBaseline）、以歷史滯後特徵訓練的 Ridge／Random Forest（RF）／HistGradientBoosting（HGB），以及加入全國選前民調與候選人政綱特徵後的表現。

研究的故事線有五步。第一，**基準很難打**：在 2012、2016、2020、2024 四個測試屆中，上屆基準平均 MAE 為 **0.0793**，優於 History RF（0.1041）、HGB（0.1257）與 Ridge（0.1776）；鄉鎮層（368 鄉鎮市區／屆）基準亦約 0.076。第二，**模型其實在抄上屆**：鄉鎮層 permutation importance 顯示樹模型 92.6%–100% 的正向重要性集中於上屆得票率 `prev`。第三，**民調是突破口**：本研究整理 5,165 列／1,607 筆 2000–2024 選前全國民調，以「上屆縣市得票＋全國民調擺盪」構成的無參數 UniformPollSwing 平均 MAE 降至 **0.0266**（2012 0.029、2016 0.020、2020 0.033、2024 0.024），History+Poll Ridge 為 0.0611。資料清理亦帶來一課：修正 2020 年日／月對調的日期後，60 日窗內民調由約 114 筆降為 53 筆，2020 誤差由 0.020 回升至 0.033——錯誤資料會系統性地讓結果「看起來更好」。擬合分析進一步顯示，縣市在描述上約跟隨全國民調擺盪的四分之三（合併面板 OLS 擺盪權重 $c = 0.747$，95% CI [0.693, 0.801]，$R^2 \approx 0.955$），但擬合出的權重在時間外推下反而較差（FittedSwing OOT 0.0575），固定權重 1 的 UniformPollSwing 最穩健。第四，**政綱尚未成熟**：510 列政綱長表的消融結果不穩定（History+Platform Ridge 0.1113、History+Poll+Platform Ridge 0.1064），未能在民調之上帶來增益。第五，**空間模型增益有限（Guide RQ2）**：在與家族 A 相同的縣市 OOT 窗下，PreviousShare 平均 MAE 仍為 **0.0793**；最佳 SGC+RF（dist_decay_bin）僅以約 **0.0015** 的幅度略勝 NonSpatial RF（0.1029 vs 0.1043），可訓練 GCN／GAT／ResidualGCN 跨年平均更差且逐年極不穩定。

研究結論是：台灣縣市得票的**相對地理結構相當穩定**，而**全國擺盪**才是預測誤差的主要來源；全國選前民調正好補上這一塊，而空間圖模型在短面板下未能穩定改寫基準故事。上述結論受制於僅四個測試屆、只有全國層級民調、區間預測未校準、TEDS 調查資料尚未整合、政綱來源未覆核與縣市圖規模極小（N=22）等限制，本文不作勝選機率或因果宣稱。

關鍵詞：台灣總統選舉；縣市得票率；時間外推回測；均勻擺盪；民意調查；特徵消融；資料品質

Keywords: Taiwan presidential election; county vote share; out-of-time backtest; uniform swing; opinion polls; feature ablation; data quality

目錄

摘要

1　引言與研究動機

2　相關研究

3　資料

4　研究方法

5　研究結果：一條由基準走向民調的故事線

6　討論

7　研究限制與未來工作

8　結論

參考資料

附錄 A　重現性：腳本、路徑與指令

附錄 B　數字版本對照與圖表資料來源

附錄 C　其他特徵權重視角

1 引言與研究動機

1.1 為什麼預測台灣總統選舉既困難又有趣

台灣自 1996 年起直選總統，本研究可取得完整縣市資料的 2000–2024 年共有七屆。與美國等有數十屆歷史、數千個縣級單位的選舉相比，台灣的「時間維度」極短：若要做嚴格的時間外推（只用過去預測未來），扣除滯後特徵所需的暖身期後，可評估的測試屆只剩 2012、2016、2020、2024 四屆，每屆 22 個縣市。這意味著任何機器學習模型在訓練時，最多也只看過四屆、88 個縣市×年份的樣本（見表 5 註）。

另一方面，台灣的政治版圖具有明顯而持續的地理結構（俗稱的「北藍南綠」[citation needed]）：圖 1(b) 顯示，各縣市本屆民進黨得票率與上屆得票率高度沿著同一條斜線排列，只是整條線隨每屆全國情勢上下平移。換言之，「**誰相對比較綠**」**很容易預測**，「**今年整體有多綠**」**才是難題**。2016 年民進黨全國得票率由 0.456 升至 0.561，2024 年則由 0.571 跌至 0.401（由縣市面板加總計算），這類全國擺盪無法從縣市的歷史滯後特徵推知。

此外，台灣選舉還有第三勢力（2000 年宋楚瑜、2024 年柯文哲）造成的多黨分票、選前約十日的民調公布禁止期（以 2004 年為例，約自 3 月 10 日起，見 `docs/taiwan_polls_2004_sources.md`），以及網路上二手民調表格日期格式混亂等資料問題。這些特性使台灣成為檢驗「簡單基準 vs. 複雜模型」與「資料品質如何影響結論」的好案例。

1.2 研究問題

本研究將問題拆成四個可在同一回測窗口下檢驗的研究問題（Research Questions, RQ）：

1. **RQ1（基準）**：在嚴格 OOT 回測下，以歷史滯後／變化特徵訓練的 Ridge、RF、HGB 能否勝過「照抄上屆」的 PreviousElectionBaseline？
2. **RQ2（依賴）**：這些模型實際上依賴哪些特徵？它們是否學到上屆結果以外的結構？
3. **RQ3（民調）**：加入全國選前民調（60 日窗）後，縣市預測誤差能否明顯下降？最簡單的 UniformPollSwing 與學習型 History+Poll 模型孰優？
4. **RQ4（政綱）**：以候選人政綱議題強調差異建構的特徵，能否在歷史或民調之上帶來穩健增益？
5. **RQ5（空間；對齊 Guide RQ2）**：在與家族 A 相同的縣市 OOT 窗下，SGC 擴散與可訓練 GCN／GAT／ResidualGCN 能否穩定勝過 NonSpatial 與 PreviousShare？

此外，本研究把一次真實發生的資料清理錯誤（2020 年民調日期日／月對調）當作「附帶研究問題」，記錄它如何改變結論。

1.3 研究定位與貢獻

本研究是**方法論回測研究**：比較不同資訊來源在 OOT 設定下對縣市得票份額 MAE 的影響，**不是**勝選預測，亦不對議題或政策作因果歸因（對應 `GUIDE_ALIGNED_ISSUE_TRACKER_2026-10-27.md` 的用語規範）。主要貢獻包括：（1）一份可重現的 22 縣市×7 屆總統得票面板與 OOT 回測管線；（2）一份經日期品質修正、可追溯來源的 2000–2024 選前全國民調長表（5,165 列／1,607 筆）；（3）一個平均誤差約為強基準三分之一的簡單民調擺盪方法；（4）對政綱特徵的誠實負面結果與資料缺口盤點；（5）與家族 A 同窗的縣市空間 RQ2（Queen／k-NN／距離衰減；SGC＋可訓練 GCN／GAT），結論為空間增益微弱且不穩定。

2 相關研究

選舉預測文獻大致可分為三條路線 [citation needed]：（1）**結構／基本面模型**，以經濟、執政表現與前屆結果預測得票；（2）**民調彙整模型**，以多家民調的加權平均與機構效應校正推估選民意向；（3）**混合模型**，把歷史地理結構與當屆民調結合，將全國訊息分配到地區層級。英國選舉研究中的「均勻擺盪」（uniform swing）概念——假設各選區相對上屆的變動與全國變動相同——是第三條路線中最簡單的形式 [citation needed]，本研究的 UniformPollSwing 即屬此類。

在台灣選舉研究方面，專案 `methodology.md` 第 10 節整理了三個方法來源：以「簡單迴歸 → 縣市固定效果 → 縣市＋屆次固定效果」比較經濟投票的面板模型（中研院人社中心期刊 PDF）、以鄰近縣市空間權重檢定 Moran's I 的政治版圖空間分析（同上），以及以分類與迴歸樹（CART）預測 2012／2016 總統選舉的碩士論文（臺灣博碩士論文知識加值系統）；這些來源的作者、年份與卷期仍待補齊 [citation needed]。區間預測方面，專案的探索性 conformal 實驗參考 Gibbs 與 Candès（2021）的 Adaptive Conformal Inference。

資料面，本研究依賴中央選舉委員會（CEC）選舉資料庫與政治大學選舉研究中心（NCCU ESC）整理之歷屆縣市得票表、維基百科（中、英文）各屆總統選舉民調表格，以及台灣選舉與民主化調查（TEDS）。與既有研究相比，本研究的重點不在提出新模型，而在於**嚴格的時間外推協定、與強基準的對照，以及資料品質的透明紀錄**。

3 資料

3.1 縣市總統得票面板（2000–2024）

核心面板為 `tw-election-forecast/data/county_panel_features_2000_2024.csv`，涵蓋 22 個縣市（以現行行政區劃整併）× 7 屆總統選舉，共 154 列。2012–2024 年得票與投票率取自 CEC 選舉資料庫；2000、2004、2008 年縣市政黨得票則轉錄自 NCCU ESC 依 CEC 資料整理的表格（`docs/DATA_AND_METHODS.md`）。預測標的為 `target_DPP_vote_share` = DPP 得票 ／ 有效票。所有誤差以比例表示：MAE 0.05 即 5 個百分點。

特徵僅使用選前已知的選舉歷史：上屆（`prev_*`）與上上屆（`prev2_*`）的 DPP／KMT／其他得票率與投票率、兩屆間變化（swing）、每年變化率、政黨間差距（margin）及前屆變動的平均與標準差。核心回測（家族 A）使用 16 個歷史特徵；消融腳本沿用 `train_taiwan_forecast.py` 的 LAG＋CHANGE 特徵，共 14 個（見 `taiwan_poll_ablation_metrics.csv` 的 `feature_count` 欄）。

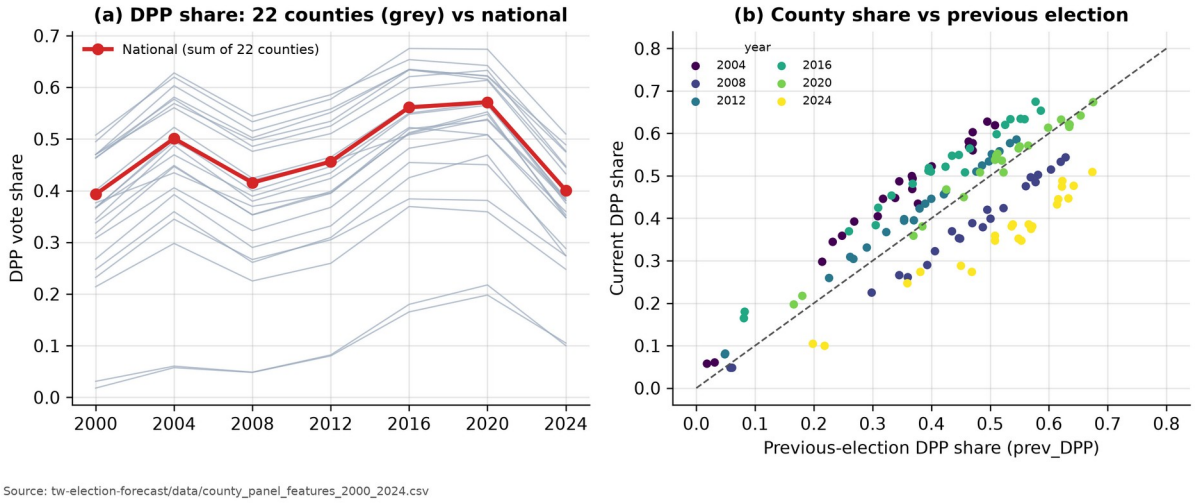


圖 1　政治地理的穩定性。(a) 22 個縣市（灰線）與全國（紅線，由 22 縣市得票加總）民進黨得票率，2000–2024。(b) 各縣市本屆得票率對上屆得票率的散布圖，顏色代表選舉年份；虛線為 45 度線。各年的點雲大致平行於 45 度線，但整體上下平移——這正是「相對結構穩定、全國擺盪難測」的視覺證據，也解釋了為何上屆基準強而 2016、2024 年誤差較大。資料：`county_panel_features_2000_2024.csv`。

3.2 選前全國民調（2000–2024）

民調資料由專案腳本 `scripts/scrape_taiwan_polls_wikipedia.py` 自中、英文維基百科各屆總統選舉民調表格爬取，**只保留選前**（`field_end` < 選舉日）的支持度題（`question_type = support`），並經 `src/prepare_taiwan_polls.py` 驗證正規化為長表 `outputs/metrics/taiwan_polls_long.csv`。最終可用 **5,165 列、1,607 筆民調**，全部為**全國層級**（`region = national`），時間跨度為 2000-01-17 至 2024-01-01

（taiwan_polls_summary.json）。來源列數以 zh.wikipedia.org 3,764 列、en.wikipedia.org 1,385 列為主。

2004 年維基百科沒有逐筆民調表，專案另以 TVBS 一手報導及 VOA、CCTV、Stratfor 的二次引用補登 **8 筆民調／16 列**（docs/taiwan_polls_2004_sources.md），並刻意排除出口民調、政黨內部民調與無法交叉確認的引用。抽樣檢查（docs/taiwan_polls_QA_spotcheck.md）確認無選後列、數值皆在 0–100 之間，但多數列缺 sample_size 與 method，部分 2024 年中文表日期僅為「發布日期」。

表 1　各屆選前全國民調數量（清理後）

選舉年	民調筆數	資料列數	60 日窗內筆數*	其中可用於特徵*	備註
2000	22	88	21	21	1 筆 1999 年六次平均已剔除
2004	8	16	8	8	一手 TVBS＋二次引用
2008	73	209	34	34	en.wikipedia
2012	295	1056	86	86	
2016	201	747	55	55	
2020	699	1835	53	53	280 列日期已修正
2024	309	1214	40	10	部分為發布日期
合計	**1,607**	**5,165**	—	—	**全部為全國層級**

資料：outputs/metrics/taiwan_polls_long.csv。*由本報告以 scripts/run_taiwan_poll_ablation.py 相同規則（選前 60 日、排除未表態、DPP 候選人須唯一配對）自長表重新計算；2024 年窗內 40 筆中僅 10 筆通過候選人名稱配對，屬待改進之處。

3.3　候選人政綱長表

政綱資料 inputs/taiwan_platforms_long.csv 共 **510 列**，欄位包括年份、候選人、政黨、議題類別、立場原文、來源網址、發布日期、pre_election_flag 與 verified。值得注意的是，總統選舉公報自 1996 年以來**不刊登**政見正文（風傳媒 2020-01-09 說明，見 docs/taiwan_platforms_2000_2020_fill.md），故僅 2024 年可由 CEC 公報 OCR 取得賴清德、柯文哲、侯友宜政見（102 列）；2000 與 2020 年改以遠見、華視、Taipei Times、風傳媒、中央社等新聞整理補齊（17 列與 62 列）；其餘年份多來自維基百科。所有列的 verified 欄仍為空白。

議題分為 13 類，列數最多的是經濟/產業（113）、兩岸/國防（111）、能源/環境（53）。進入模型的只有 pre_election_flag = 1 的列；2004 年 51 列全為待審（review），因此 2004 年政綱特徵為缺值。

表 2　政綱長表各屆列數與 DPP／主要對手覆蓋

選舉年	總列數	選前列（使用）	待審列（排除）	DPP 列	主要對手列	覆蓋平衡
2000	17	17	0	5	5	0.50
2004	51	0	51	0	0	—
2008	173	133	40	39	93	0.30
2012	61	60	1	22	24	0.48
2016	44	44	0	12	11	0.48
2020	62	62	0	19	24	0.44
2024	102	95	7	47	21	0.31
合計	**510**	**411**	**99**	—	—	—

資料：`inputs/taiwan_platforms_long.csv`；DPP／對手列數與覆蓋平衡取自 `outputs/metrics/taiwan_platform_ablation_summary.json`（2016 年對手為朱立倫）。

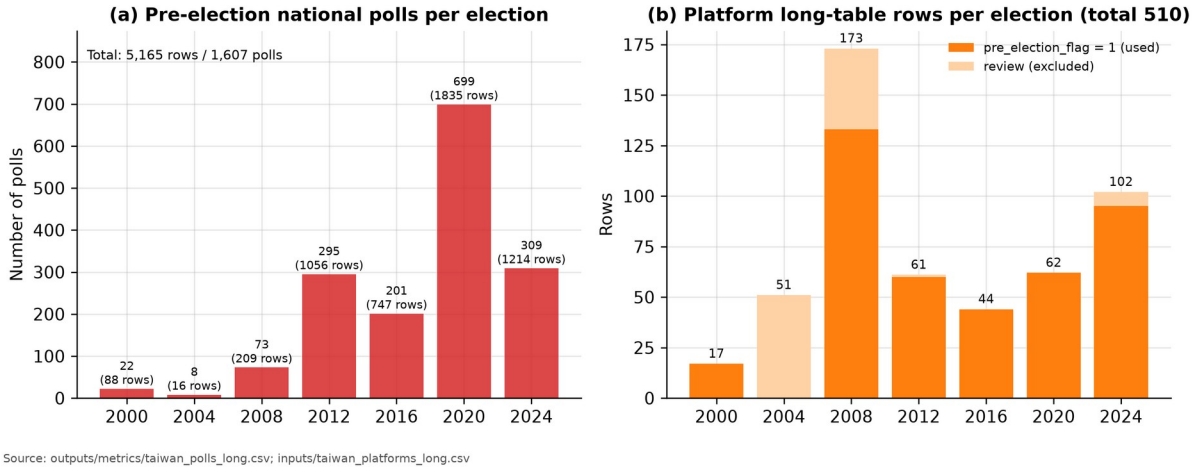


圖 2　資料覆蓋。(a) 各屆清理後選前全國民調筆數（括號內為資料列數）：2020 年最多（699 筆），2004 年僅 8 筆，早年資料明顯稀疏。(b) 政綱長表各屆列數，深色為進入模型的選前列、淺色為排除的待審列；2008 年列數最多但 DPP 與對手覆蓋不均，2004 年全數待審。兩圖共同說明：民調與政綱的資訊量在時間上極不均勻，這是後續消融結果需保守解讀的原因之一。

3.4　鄉鎮層面板

為檢驗模型依賴，本研究亦使用 2004–2024 年鄉鎮市區面板（每個測試屆 368 個鄉鎮市區），僅含選舉得票與投票率衍生特徵（`prev`、`prev2`、`swing`、`turnout_prev`），不含民調或社經變數（`township_permutation_importance_summary.md`）。

3.5　TEDS 調查資料現況

TEDS 選前電訪波次（例如 TEDS2024-T，2023-12-22 至 2024-01-12，三波獨立樣本 998／1,078／971 人）可提供政黨認同、統獨立場、施政滿意度等個體層資訊。其原始資料須由研究者本人在 TEDS 官網或中研院學術調查研究資料庫（SRDA）註冊申請，本專案未繞過任何登入，因此 **TEDS 尚未整合進特徵**；`docs/TEDS_access_and_item_map.md` 已列出申請途徑、選前波次與題目→特徵對照，作為未來工作。

表 3　資料來源總覽

資料	規模	時間	層級	狀態
縣市總統得票面板	22 縣市 × 7 屆 = 154 列	2000–2024	縣市	已整合（CEC／NCCU ESC）
鄉鎮面板	368 鄉鎮市區／測試屆	2004–2024	鄉鎮	已整合（僅選舉特徵）
選前民調	5,165 列／1,607 筆	2000–2024	全國	已整合（維基＋2004 補登）
政綱長表	510 列（選前 411 列）	2000–2024	全國	探索性；未覆核
TEDS 選前調查	—	2012–2024（待核）	個體	未整合；需 SRDA 註冊

4　研究方法

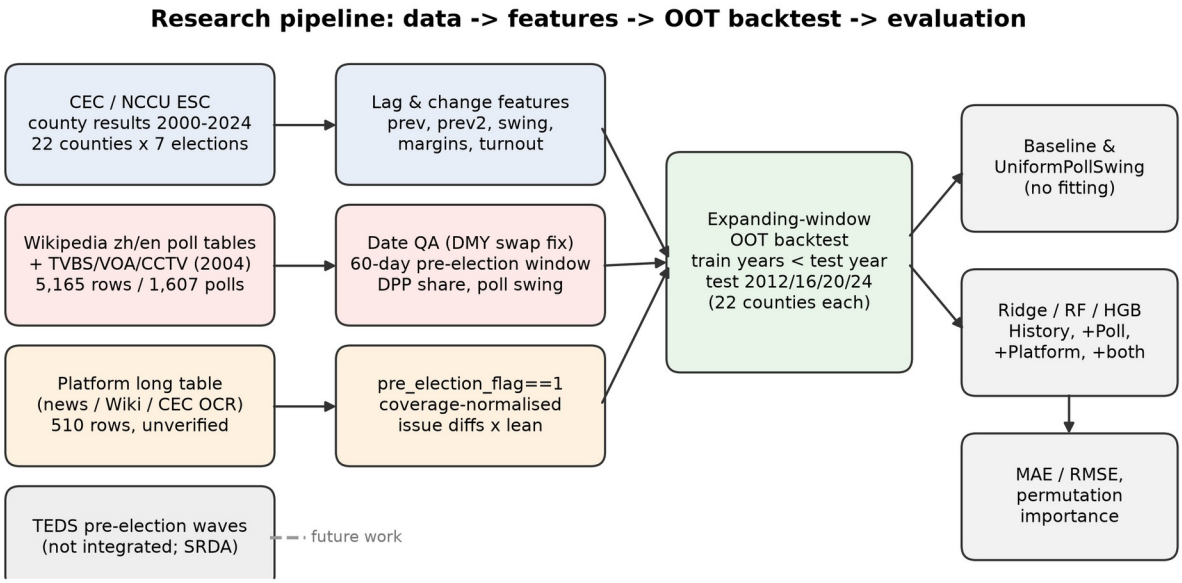


圖 3　研究管線。四類資料來源（左）經特徵工程（中左）後，進入同一個 expanding-window 時間外推回測（中右）；評估端（右）包括不需擬合的 PreviousElectionBaseline 與 UniformPollSwing、學習型 Ridge／RF／HGB 的四種特徵組合，以及 MAE／RMSE 與 permutation importance。TEDS 以虛線表示尚未整合。

4.1　時間外推（OOT）回測協定

採 expanding window：對每個測試年 t，只用 t 之前的選舉訓練，並一次測試該年全部 22 個縣市；不做隨機切分，也不讓任何未來選舉進入訓練。由於滯後特徵需要至少兩屆歷史，2008 年是第一個特徵完整的年份，因此學習型模型的可比測試屆為 2012（以 2008 訓練）、2016、2020、2024，訓練列數分別為 22、44、66、88。2004／2008 年只能計算不需訓練的 UniformPollSwing，圖中以陰影或星號標示為「部分年份」。

4.2　基準與學習模型

- **PreviousElectionBaseline**：預測值 = 該縣市上屆 DPP 得票率（`prev_DPP`）。

- **Ridge**：`StandardScaler` + `Ridge(alpha=10)`，標準化只在訓練折內擬合。
- **Random Forest**：300 棵樹、`min_samples_leaf=3`、`random_state=42`。
- **HistGradientBoosting**：150 次迭代、學習率 0.06、最多 7 葉、最小葉 5、L2 正則 1.0、`random_state=42`。

以上規格為核心回測 `scripts/taiwan_core_backtest.py` 之設定（`docs/DATA_AND_METHODS.md`）；消融實驗透過 `train_taiwan_forecast.py` 的 `expanding_window_backtest` 執行，兩條管線的平均 MAE 有微小差異（見附錄 B）。

4.3 UniformPollSwing

UniformPollSwing 是本研究最核心的方法，完全不需擬合：

$$\hat{y}(i,t) = \text{clip}(\ \text{prev_DPP}(i,t) + [\ \text{poll_share}(t) - \text{national_DPP}(t-1)\ ],\ 0,\ 1\ )$$

其中 `poll_share(t)` 為選前 60 日內各筆民調中 DPP 候選人支持度占具名候選人合計（排除未表態）的比例之平均，`national_DPP(t-1)` 為上屆全國 DPP 得票率（由 22 縣市加總）。直覺上，它把「上屆的相對地理結構」與「民調告訴我們今年全國往哪裡擺」拼在一起，並假設每個縣市擺盪幅度相同。

4.4 特徵工程

- **History**：上屆／上上屆得票、swing、margin、投票率等 14 個滯後與變化特徵。
- **Poll**：`poll_dpp_share`（60 日窗平均正規化支持度）與 `poll_swing`（相對上屆全國得票）；兩者為全國常數，每屆同值套用至 22 縣市。
- **Platform**：僅用選前列；在 DPP 候選人與主要對手陣營內做覆蓋正規化的議題份額，取差值 `plat_diff_*`（兩岸/國防、經濟/產業、能源/環境、社福/長照/年金、司法/政治改革、教育/文化），加上關鍵詞差（台獨／九二／核能綠能／長照），以及與縣市傾向的互動項 `plat_diff_* × (prev_DPP − 0.5)`；原始列數不入模，只保留 `plat_coverage_balance`。

4.5 消融設計

表 4　消融實驗矩陣（所有實驗共享同一 OOT 窗與測試列）

實驗	特徵	模型	用途
History	14 個歷史特徵	Baseline／Ridge／RF／HGB	RQ1：基準是否可被擊敗
History+Poll	History + 2 個民調特徵	同上	RQ3：民調增益
UniformPollSwing	prev_DPP + poll_swing	無擬合	RQ3：最簡單的民調結合
History+Platform	History + 政綱特徵	同上	RQ4：政綱增益
History+Poll+Platform	History + 民調 + 政綱	同上	RQ4：政綱在民調之上是否

實驗	特徵	模型	用途
			有增益
Township LagOnly／LagAndChange	prev, turnout_prev（＋prev2, swing）	RF／HGB	特徵依賴（permutation）
FittedSwing（擬合分析）	a + b·prev_DPP + c·poll_swing	OLS（HC1）／expanding	權重解讀與過擬合檢查
County Spatial RQ2	Family A 16 歷史特徵＋圖擴散／GNN	PreviousShare／NonSpatial／SGC／GCN／GAT	RQ5／Guide RQ2

4.6 洩漏控制

- 時間切割：訓練年 < 測試年；每個測試年整屆一起預測。
- 民調只用 `field_end` < 選舉日且落於選前 60 日窗的資料；出口民調與投票日民調排除。
- 政綱只用 `pre_election_flag = 1` 的當屆選前文本；不使用任何得票結果建構文字特徵。
- 標準化與插補只在訓練折內擬合；固定隨機種子 42。
- 日期品質：修正 `YYYY-DD-MM` 對調，避免無效日期以字串比較誤入時間窗（見 5.4 節）。

4.7 評估指標與重要性

此外，為解讀特徵權重與模型擬合，本研究以 `scripts/fit_feature_weights.py` 在 2008–2024 合併面板（n = 110 個縣市×年份）上估計 OLS（HC1 穩健標準誤）與擺盪權重模型，並將樣本內誤差與 OOT 誤差並列比較（5.5 節）。這些係數是在全部年份上擬合，屬描述性的預測關聯，不能當作預測表現或因果效果。

主要指標為縣市平均絕對誤差（MAE），輔以 RMSE；每個縣市等權重，先逐屆計算再取四屆平均。重要性採 permutation importance：在未參與訓練的測試屆上把單一特徵隨機打亂 30 次，計算 MAE 的平均增加，並以正向重要性的份額（`pct_of_positive_importance`）呈現。重要性只描述**模型在回測中的依賴**，不代表因果。

5 研究結果：一條由基準走向民調的故事線

5.1 第一幕：上屆結果是很難打敗的基準

表 5 與圖 4 顯示純歷史特徵模型的 OOT 表現。四屆平均下，PreviousElectionBaseline 的 MAE 為 **0.0793**，優於 History RF（0.1041）、HGB（0.1257）與 Ridge（0.1776）。逐屆來看，學習模型偶爾在單屆勝出（例如 2024 年 HGB 0.0926 低於基準 0.1596），但也會出現嚴重失誤

——2020 年 Ridge 的 MAE 高達 0.3956，而同年基準只有 0.0193。在只有 22–88 列訓練資料的短面板中，彈性較高的模型容易過度擬合前幾屆的擺盪方向。

表 5　History 實驗逐屆縣市 MAE（越低越好）

模型	2012	2016	2020	2024	平均
PreviousElectionBaseline	**0.0402**	**0.0979**	**0.0193**	**0.1596**	**0.0793**
History Ridge	0.0433	0.1256	0.3956	0.1459	0.1776
History RF	0.0691	0.1332	0.0482	0.1661	0.1041
History HGB	0.1170	0.2222	0.0709	0.0926	0.1257

資料：`outputs/metrics/taiwan_poll_ablation_metrics.csv`（experiment = History）。訓練列數 22／44／66／88，測試列數每屆 22。

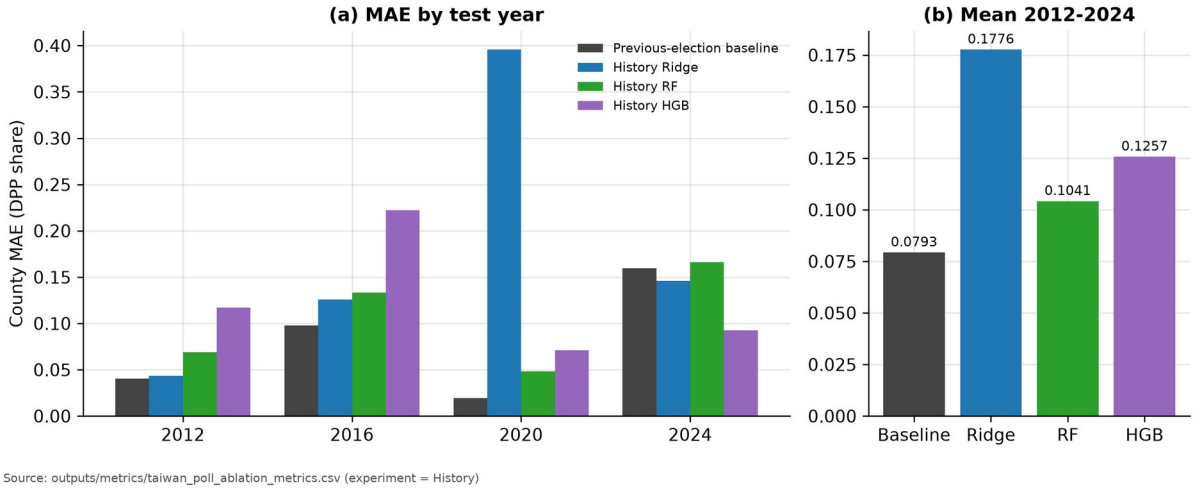


圖 4　基準很難打。(a) 各測試屆縣市 MAE：深灰為上屆基準，藍、綠、紫分別為 History Ridge、RF、HGB；(b) 2012–2024 四屆平均。基準在平均上最佳，學習模型的誤差在屆與屆之間大幅波動（Ridge 2020 的尖峰最明顯）。資料：`taiwan_poll_ablation_metrics.csv`。

此結論亦在獨立的核心回測管線（家族 A，`analysis/taiwan_core/`）中重現：基準 0.0793 < RF 0.1040 < HGB 0.1189 < Ridge 0.1786，且同一環境重跑可重現至浮點精度（`REPRODUCIBILITY.md`）。鄉鎮層的結果也一致：368 個鄉鎮市區、四個測試屆下，基準平均 MAE 約 **0.076**（0.0762），所有 RF／HGB 組合皆落在 0.1207–0.1248，比基準差 0.044–0.049。

5.2　第二幕：模型其實在「抄上屆」

既然學習模型打不過基準，它們學到了什麼？圖 5(a) 的鄉鎮層 permutation importance 給出直接答案：在 LagOnly 設定下，RF 有 **100%**、HGB 有 **99.1%** 的正向重要性來自上屆得票率 `prev`；即使加入 `prev2` 與 `swing`（LagAndChange），`prev` 仍占 RF 的 92.6% 與 HGB 的 99.6%，`swing` 與 `turnout_prev` 幾乎為零。換言之，複雜模型並沒有發現比「上屆結果」更強的結構，只是以帶雜訊的方式近似它——而這種近似本身就會引入額外誤差（圖 5(b)）。

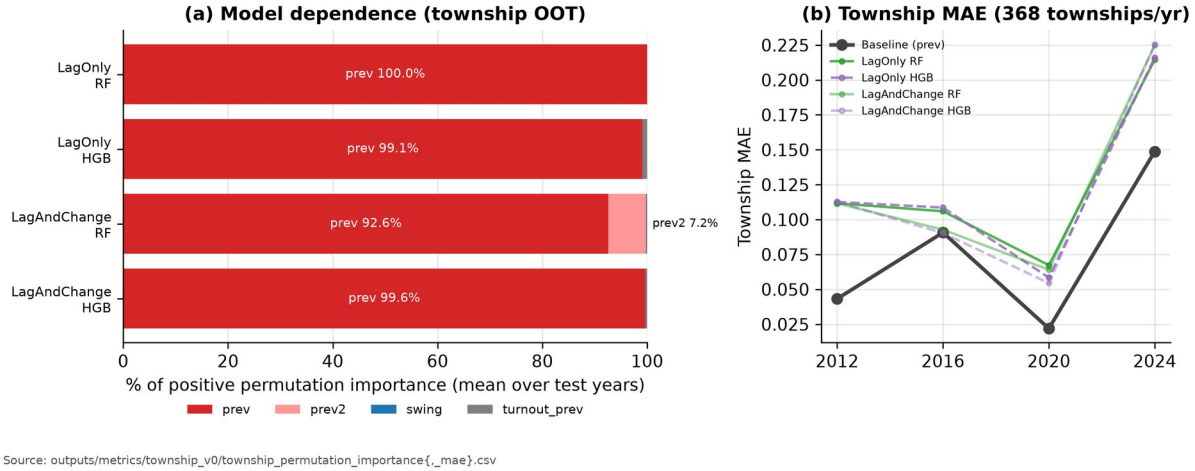


圖 5　模型依賴（非因果）。(a) 鄉鎮層 OOT permutation importance 的正向份額（四個測試屆平均），紅色為上屆得票率 `prev`，在四種模型／特徵組合中占 92.6%–100%；(b) 鄉鎮層逐屆 MAE，粗灰線為上屆基準，其餘為 RF／HGB。模型幾乎完全依賴 `prev`，卻在每一屆都比直接使用 `prev` 更差。資料：`outputs/metrics/township_v0/`。

縣市層核心回測的重要性排名（`analysis/taiwan_core/summary.json`）也指向同一群特徵：上上屆 DPP 得票、上屆 DPP 得票、上屆 KMT 得票與 DPP–KMT 差距反覆名列前茅。這些都是「地理結構」的不同表達方式；**歷史特徵能描述誰比較綠，卻無法告訴模型今年全國會往哪裡擺**。這正是下一幕的切入點。

5.3　第三幕：全國民調帶來突破

把選前 60 日的全國民調加入後，情勢明顯改變（圖 6、圖 7、表 6）。最簡單的 UniformPollSwing 在四個測試屆的平均 MAE 降至 **0.0266**，約為基準 0.0793 的三分之一，且**每一屆都**維持在 0.020–0.033 之間（2012 0.0290、2016 0.0202、2020 0.0329、2024 0.0244）。學習型 History+Poll Ridge 亦降至 **0.0611**，優於基準與純 History Ridge（0.1776）；但 History+Poll RF（0.1036）與 HGB（0.1235）幾乎沒有改善——樹模型無法對訓練期未見過的全國常數值做外推。

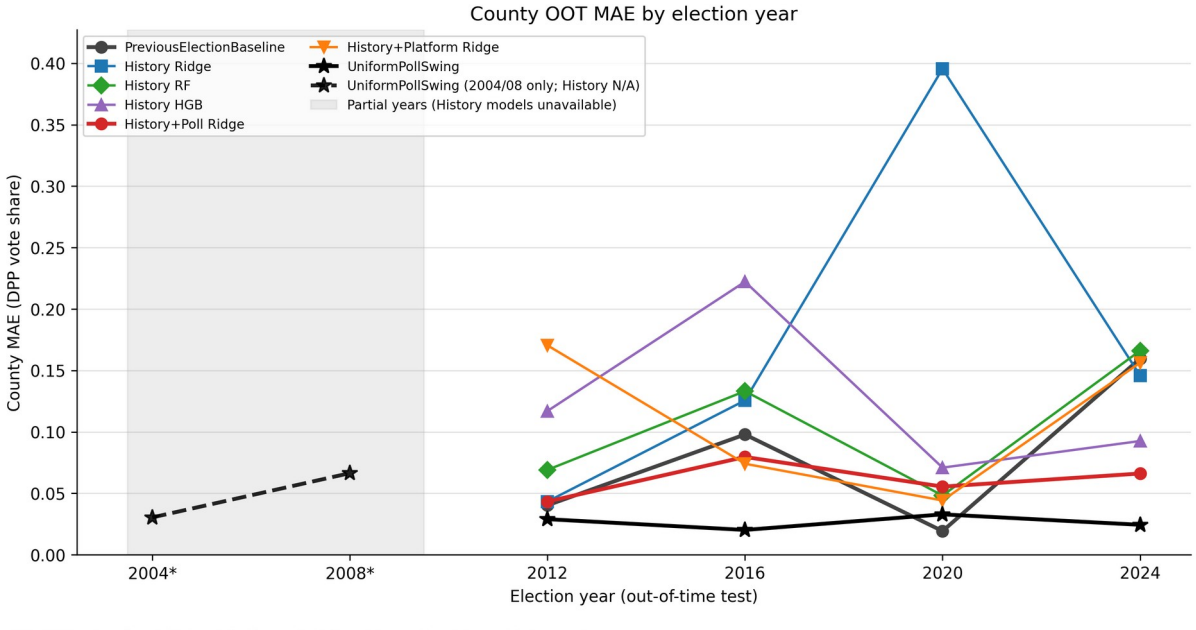


圖 6　核心結果一：各測試屆縣市 OOT MAE。灰色陰影的 2004*／2008* 只有 UniformPollSwing（黑色星號）可計算；2012 年後，黑線（UniformPollSwing）除 2020 年（基準 0.019 較低）外皆位於最底部，而上屆基準（深灰）在 2016 與 2024 兩次大擺盪年明顯上升。資料：`taiwan_platform_ablation_metrics.csv`、`taiwan_poll_ablation_metrics.csv`（圖由 `scripts/plot_core_mae_figures.py` 產生）。

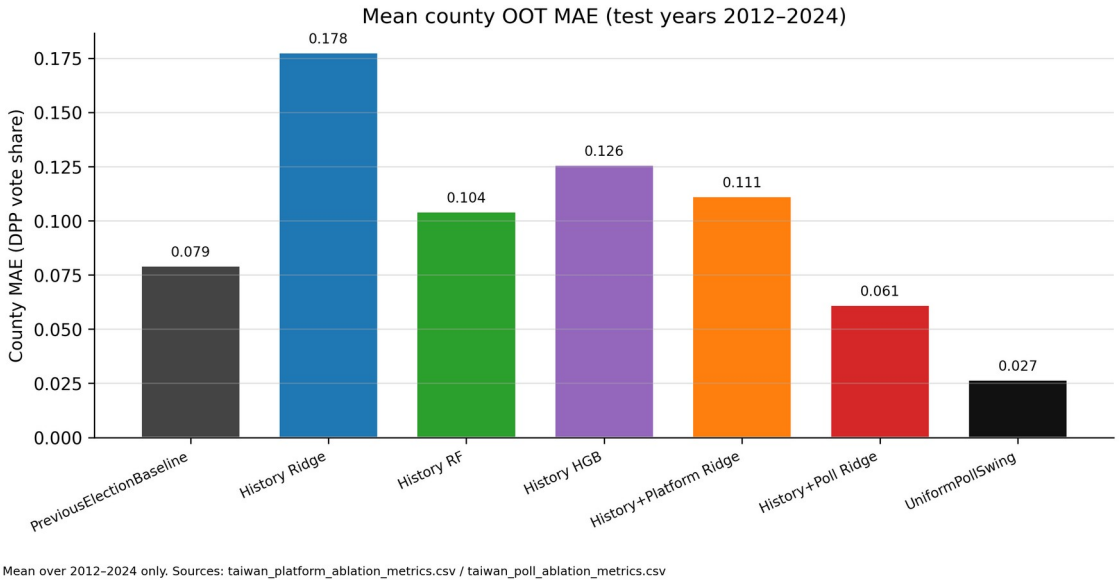


圖 7　核心結果二：2012–2024 四屆平均縣市 MAE。由左至右的排序清楚呈現故事線：純歷史學習模型（0.104–0.178）不如上屆基準（0.079）；加入民調後 Ridge 降至 0.061；最簡單的 UniformPollSwing 最佳（0.027）。政綱（橘色，0.111）未能勝過基準。

表 6　民調消融逐屆縣市 MAE

模型	2004*	2008*	2012	2016	2020	2024	平均 2012–24
PreviousElectionBaseline	—	—	0.0402	0.0979	0.0193	0.1596	0.0793
History Ridge	—	—	0.0433	0.1256	0.3956	0.1459	0.1776
History+Poll Ridge	—	—	0.0433	0.0796	0.0555	0.0661	0.0611
History+Poll RF	—	—	0.0701	0.1324	0.0483	0.1638	0.1036

模型	2004*	2008*	2012	2016	2020	2024	平均 2012–24
History+Poll HGB	—	—	0.1170	0.2222	0.0709	0.0839	0.1235
UniformPollSwing	**0.0304**	**0.0664**	**0.0290**	**0.0202**	**0.0329**	**0.0244**	**0.0266**

資料：`outputs/metrics/taiwan_poll_ablation_metrics.csv`。*2004／2008 只有 UniformPollSwing 可計算，不納入平均。

為什麼民調如此有效？圖 8(a) 比較「民調擺盪」（60 日窗民調 DPP 份額減上屆全國得票率）與實際全國擺盪：在 2004、2016、2024 年兩者方向與幅度都相當接近，其中 2024 年民調擺盪為 -0.164，實際為 -0.171（本報告依消融腳本規則自長表重新計算）。正因如此，2024 年基準誤差高達 0.1596，而 UniformPollSwing 只有 0.0244。反例同樣具啟發性：2008 年民調擺盪（-0.155）明顯大於實際（-0.086），UniformPollSwing 誤差因而升至 0.0664，是所有年份中最高的——民調的品質與代表性直接決定了方法的上限。

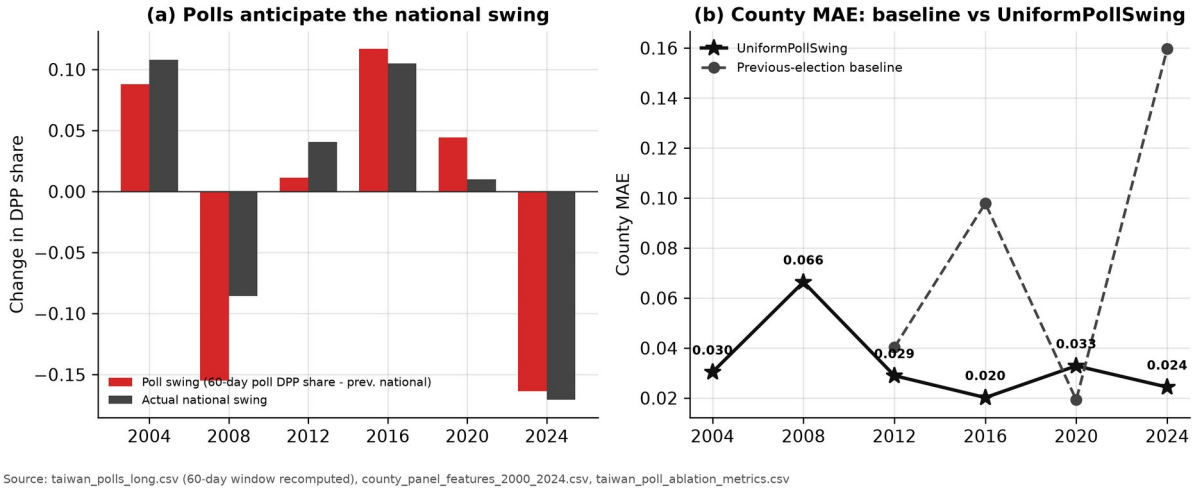


圖 8　民調捕捉全國擺盪。(a) 紅柱為民調擺盪（選前 60 日民調 DPP 正規化份額 − 上屆全國 DPP 得票率），深灰柱為實際全國擺盪；兩者方向在六屆中全部一致。(b) 縣市 MAE：UniformPollSwing（實線、星號）與上屆基準（虛線）。基準在大擺盪年（2016、2024）失準，UniformPollSwing 則保持平穩。民調份額由本報告依 `run_taiwan_poll_ablation.py` 規則自 `taiwan_polls_long.csv` 重新計算；MAE 取自 `taiwan_poll_ablation_metrics.csv`。

值得強調的是，學習型 History+Poll Ridge（0.0611）仍不如無參數的 UniformPollSwing（0.0266）。在只有四個測試屆的極短序列下，Ridge 必須從少數幾個不同的全國民調值中「學」出民調與得票的關係，而 UniformPollSwing 直接把這個關係假設為一比一。**簡單、可解釋且結構正確的模型，勝過彈性較高但資料不足的模型。**

5.4　插曲：一次日期錯誤教會我們的事

在民調管線的早期版本中，2020 年中文維基表格的部分日期被爬成 `YYYY-DD-MM`（例如 `2019-29-12`）。由於時間窗以字串比較篩選，這些無效日期被誤納入 2020 年的 60 日窗：窗內約有 114 筆民調，UniformPollSwing 2020 年 MAE 約為 0.0197，四屆平均為 0.0233，看起來比

現在更好。`scripts/fix_taiwan_poll_dates.py` 修正了 **280 列、102 筆**民調的日／月對調（`taiwan_polls_date_corrections.csv`），另剔除 4 列無法定出單一日期的 1999 年六次平均（`taiwan_polls_dropped_undateable.csv`）。修正後，2020 年窗內只剩 **53 筆**，MAE 回升為 **0.0329**，四屆平均變為 0.0266。

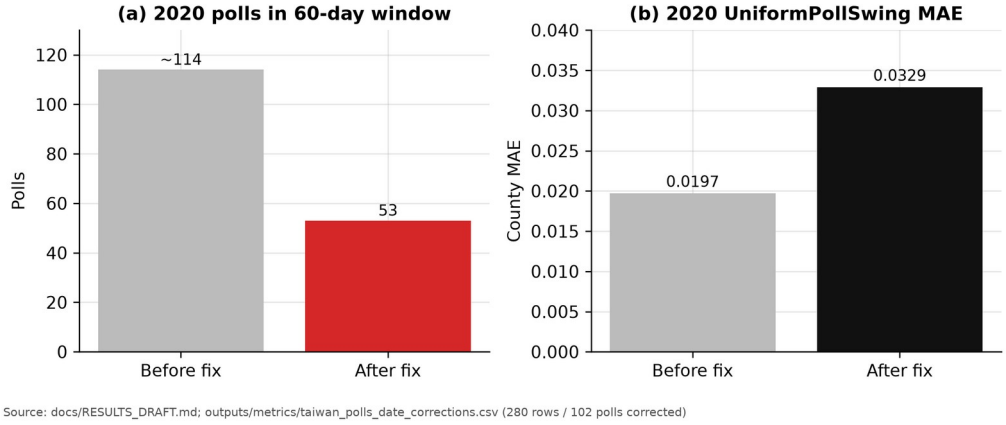


圖 9　資料清理的教訓（2020 年）。(a) 60 日窗內民調筆數由修正前約 114 筆降為 53 筆；(b) UniformPollSwing 2020 年縣市 MAE 由約 0.0197 回升至 0.0329。修正前的數字源自無效日期被字串比較誤收，代表錯誤資料讓誤差被系統性低估。修正前數值記錄於 `docs/RESULTS_DRAFT.md` 與 `GUIDE_ALIGNED_ISSUE_TRACKER_2026-10-27.md`；修正後取自 `taiwan_poll_ablation_metrics.csv`。

這段插曲的意義在於：**資料工程錯誤不一定讓結果變差，反而可能讓結果「看起來更好」**。若沒有可稽核的修正紀錄，研究者很容易把較低的誤差當成方法的勝利。本研究選擇報告數字略差、但日期可信的版本。

5.5　幕間：權重告訴我們什麼——擬合很好，不等於預測很好

UniformPollSwing 把上屆得票與民調擺盪的權重都固定為 1。一個自然的追問是：如果讓資料自己決定權重，會不會更好？本節以 2008–2024 年合併面板（n = 110 個縣市×年份，有民調特徵的列）估計擺盪權重模型 y = a + b·prev_DPP + c·poll_swing，並以 HC1 穩健標準誤計算信賴區間（`outputs/metrics/feature_weights_swing.csv`、`feature_weights_summary.json`）。

表 7　擺盪權重模型的合併面板 OLS 估計（HC1，n = 110）

參數	估計值	95% CI	UniformPollSwing 參照值
a（截距）	0.0602	[0.0394, 0.0810]	0
b（prev_DPP）	0.8747	[0.8305, 0.9188]	1
c（poll_swing）	0.7469	[0.6933, 0.8005]	1
R^2	0.955	—	0.919（樣本內）

資料：`outputs/metrics/feature_weights_swing.csv`、`feature_weights_fit_quality.csv`。三個參數的信賴區間皆不包含 UniformPollSwing 的參照值。

在描述層次上，結果相當清楚：c 的 95% 信賴區間為 [0.693, 0.801]，不包含 1，表示在合併樣本中，**全國民調擺盪每變動 1 個單位，縣市得票平均只跟著變動約四分之三**；b < 1 且 a > 0 則意味著上屆極端的縣市本屆略向中間回歸。這是預測性關聯的描述，不代表民調「造成」得票變化，也不代表縣市選民對全國情勢的反應較弱。

若把歷史與民調特徵全部放進 OLS（History+Poll，HC1），個別係數如圖 10 所示：`poll_swing` 為 0.939（95% CI [0.608, 1.270]）、`prev_DPP` 為 0.249、`prev_DPP_KMT_margin` 為 0.167，而 `poll_dpp_share` 為 −0.403。由於 `poll_dpp_share` 與 `poll_swing` 每屆都是同一組全國常數、彼此高度共線，且 `prev_DPP` 與各種 margin、swing 特徵也互相重疊，**這些係數不應逐一解讀**——負號並不表示民調支持度與得票呈負相關，而是共線特徵之間分攤權重的結果（`docs/feature_weights.md`）。

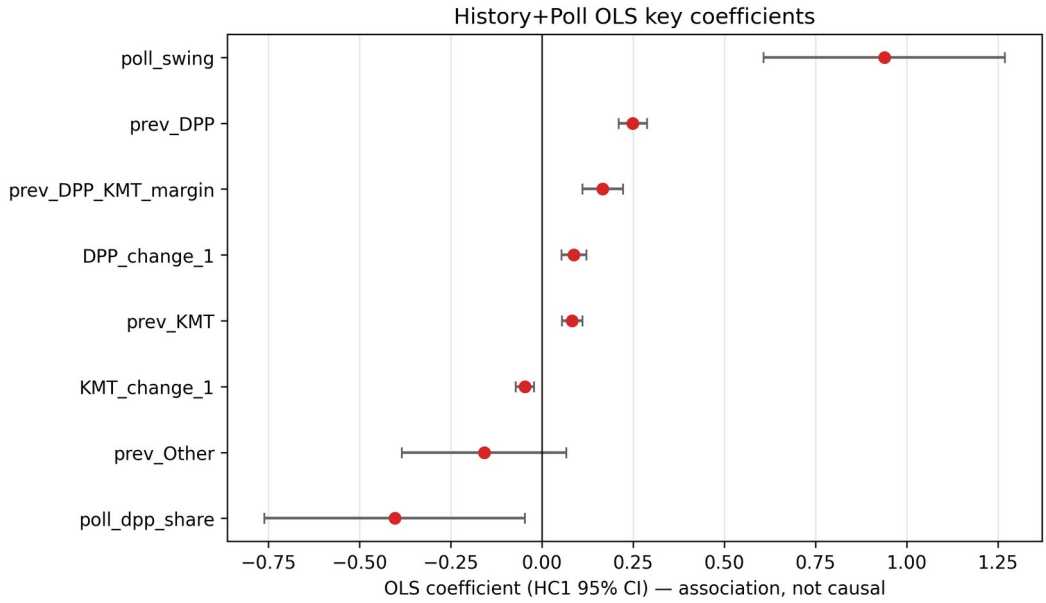


圖 10　History+Poll OLS 的主要係數與 HC1 95% 信賴區間（合併面板，n = 110）。`poll_swing` 的點估計最大但區間很寬；`poll_dpp_share` 的負號源自與 `poll_swing` 的共線性，不宜單獨解讀。所有係數皆為預測性關聯，非因果效果。資料：`outputs/metrics/feature_weights_key_coefs.csv`。

樣本內擬合看起來近乎完美：History+Poll OLS 的 R^2 為 0.986、MAE 為 0.014，實際值與預測值幾乎都落在 45 度線上，殘差也沒有明顯的年份偏誤（圖 11）。但這正是需要警惕的地方——在 110 列上擬合 16 個彼此共線的特徵（加截距共 17 個參數），擬合好幾乎是必然的。

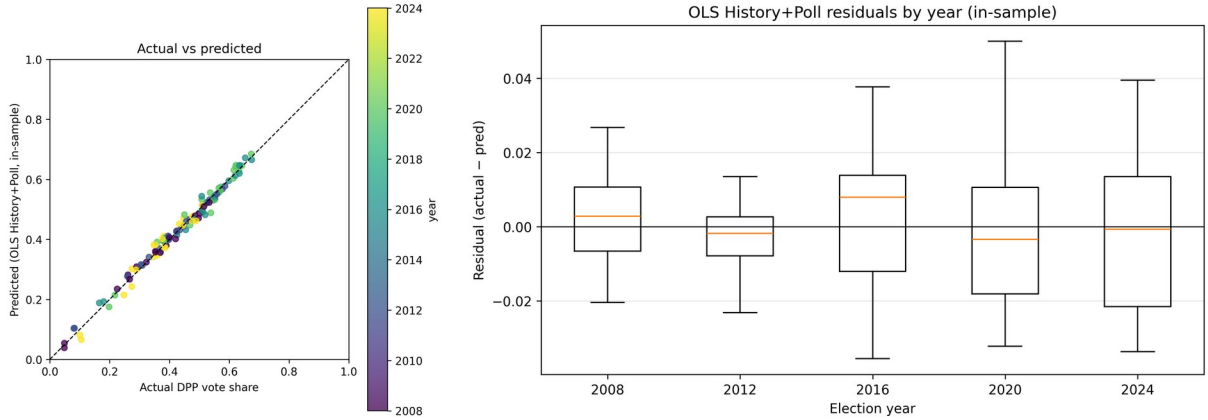


圖 11　History+Poll OLS 的樣本內診斷。(a) 實際 vs 預測 DPP 得票率，顏色為選舉年份；(b) 各年份殘差（實際 − 預測）箱形圖。樣本內誤差很小且各年大致以 0 為中心，但這是在全部年份上擬合的結果，不代表時間外推的預測能力。資料：`outputs/metrics/feature_weights_residuals.csv`。

表 8　擬合品質：樣本內 vs 時間外推（OOT）MAE

模型	樣本內 MAE	樣本內 R^2	OOT 平均 MAE（2012–2024）	OOT 來源
History（OLS）	0.0210	0.960	0.1776	消融 History Ridge（代理）
History+Poll（OLS）	0.0139	0.986	0.0611	消融 History+Poll Ridge（代理）
FittedSwing（a, b, c）	0.0254	0.955	0.0575	expanding window 重新擬合
UniformPollSwing（c = 1）	**0.0346**	**0.919**	**0.0266**	**消融（無擬合）**

資料：`outputs/metrics/feature_weights_fit_quality.csv`。樣本內為 2008–2024 合併面板（UniformPollSwing／FittedSwing 為有民調的列）；History 與 History+Poll 的 OOT 數字取自同特徵集的 Ridge 消融結果，作為 OLS 的代理，並非 OLS 本身的 OOT。

表 8 與圖 12 把兩種誤差並列，故事立刻翻轉。純歷史模型在樣本內 MAE 只有 0.021，到了時間外推卻是 0.178，相差八倍以上，是典型的過度擬合；History+Poll 由 0.014 升至 0.061；FittedSwing 由 0.025 升至 0.057。**唯一在時間外推下表現比樣本內還好的是 UniformPollSwing**（0.035 → 0.027）——它沒有任何需要估計的參數，因此也沒有東西可以過擬合。（其樣本內 MAE 較高，部分原因是合併樣本包含 2008 年，而 2008 年民調擺盪明顯大於實際擺盪，見 5.3 節。）

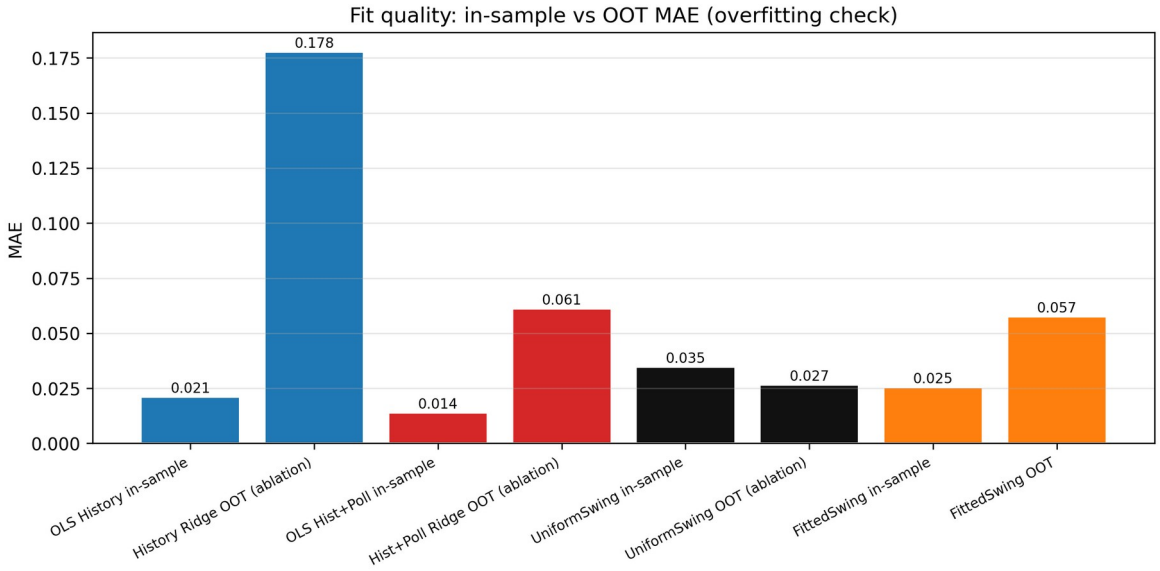


圖 12　擬合品質檢查：每種模型左柱為樣本內 MAE、右柱為 OOT 平均 MAE（2012–2024）。藍、紅兩組（History、History+Poll）與橘色 FittedSwing 從樣本內到 OOT 都大幅惡化；黑色 UniformPollSwing 是唯一 OOT 誤差低於樣本內的方法。History 與 History+Poll 的 OOT 柱為同特徵集 Ridge 消融結果。資料：`outputs/metrics/feature_weights_fit_quality.csv`。

表 9　FittedSwing 的 expanding-window 重新擬合結果

測試年	a	b	c	FittedSwing MAE	UniformPollSwing MAE
2012	-0.0266	0.8829	0.0041	0.1099	0.0290
2016	0.0541	0.9412	0.6939	0.0159	0.0202
2020	0.0481	0.9441	0.6500	0.0372	0.0329
2024	0.0542	0.9090	0.6103	0.0668	0.0244
平均	—	—	—	**0.0575**	**0.0266**

資料：`outputs/metrics/feature_weights_fitted_swing_oot.csv`；UniformPollSwing 取自 `taiwan_poll_ablation_metrics.csv`。

為什麼擬合出的權重在預測時反而較差？表 9 顯示每個測試年只用過去資料重新估計 (a, b, c) 的結果：2012 年只能用 2008 年一屆訓練，擬合出的 c 幾乎為 0（0.004），等於完全忽略民調，MAE 因而高達 0.110；之後各屆 c 落在 0.61–0.69 之間，而 2016 年 FittedSwing（0.0159）確實優於 UniformPollSwing（0.0202），但 2020、2024 年都較差。在只有一到四屆可供訓練的情況下，估計出來的權重本身就很不穩定，而且容易受個別年份（例如民調擺盪過大的 2008 年）牽動；固定為 1 的權重雖然在樣本內「不夠準」，卻不受這種估計誤差影響。

本節的結論是：**描述上，縣市大約跟隨全國擺盪的四分之三；但用於預測時，讓資料估計權重會過度擬合，固定權重 1 在時間外推下最穩健**。這也從另一個角度呼應了 5.1 節的發現——在屆次極少的台灣總統選舉中，好的樣本內擬合不能當作好的預測。隨機森林的 permutation importance 與 Ridge 標準化係數等其他權重視角見附錄 C。

5.6 第四幕：政綱特徵不穩定，也沒有在民調之上加分

最後，本研究檢驗候選人政綱是否能提供民調以外的訊息（表 10、圖 13）。History+Platform Ridge 的四屆平均 MAE 為 **0.1113**，雖優於純 History Ridge（0.1776），但仍**劣於基準**（0.0793）；而且逐屆表現極不穩定——2012 年由 0.0433 惡化至 0.1705，2016、2020 年看似改善（0.0741、0.0442），2024 年又略差（0.1563）。更關鍵的是，在民調之上再加入政綱，Ridge 由 0.0611 **惡化**至 0.1064；RF 與 HGB 加入政綱後也都在 0.109–0.110 左右，沒有任何組合接近 UniformPollSwing 的 0.0266。

表 10　政綱消融：Ridge 逐屆 MAE 與三種模型的四屆平均

實驗	2012	2016	2020	2024	Ridge 平均	RF 平均	HGB 平均
History	0.0433	0.1256	0.3956	0.1459	0.1776	0.1041	0.1257
History+Platform	0.1705	0.0741	0.0442	0.1563	0.1113	0.1092	0.1103
History+Poll	0.0433	0.0796	0.0555	0.0661	0.0611	0.1036	0.1235
History+Poll+Platform	0.1705	0.0716	0.0444	0.1393	0.1064	0.1097	0.1103
UniformPollSwing（參照）	**0.0290**	**0.0202**	**0.0329**	**0.0244**	**0.0266**	—	—

資料：`outputs/metrics/taiwan_platform_ablation_metrics.csv`（70 列實驗結果）；基準四屆平均 0.0793。

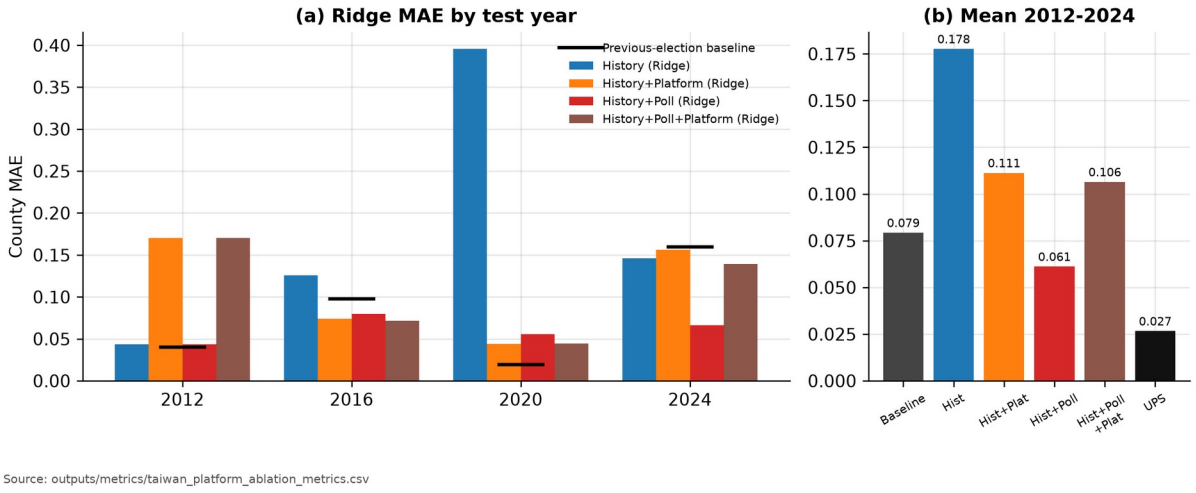


圖 13　政綱消融。(a) 四種特徵組合的 Ridge 逐屆 MAE，黑色橫線為上屆基準；政綱（橘、棕）在 2012 年造成嚴重惡化，2016／2020 年的改善不具一致性。(b) 四屆平均：政綱組合（0.111、0.106）皆不如基準（0.079），更遠不及 History+Poll Ridge（0.061）與 UniformPollSwing（0.027）。資料：`taiwan_platform_ablation_metrics.csv`。

可能的原因包括：政綱特徵是每屆一組的全國常數，四個測試屆等於只有四個不同取值，與民調特徵高度共線；來源多為二手整理且未覆核；各屆 DPP 與對手的覆蓋不均（2008 年 39 比 93、2024 年 47 比 21）。因此，本研究將政綱結果定位為**探索性的負面結果**：現有政綱表不足以構成可重複的預測增益。

5.7 第五幕：縣市空間模型（Guide RQ2）——基準仍最好，空間增益微弱

對齊 FYP Guide 的 RQ2，本研究在**與家族 A 完全相同**的縣市 expanding-window OOT 窗（測試年 2012／2016／2020／2024；目標 `target_DPP_vote_share`；16 個歷史特徵）上，比較四類方法：（1）PreviousShare；（2）NonSpatial Ridge／RF／HGB；（3）SGC 風格圖擴散（L1／L2）再接 Ridge／RF；（4）可訓練 ResidualGCN／GCN／GAT。鄰接圖由鄉鎮 GeoJSON dissolve 至縣市後建構：**Queen 共邊**（33 邊、平均度 3.0；澎湖／金門／連江為離島、度數 0）、**k-NN（k=3）**與**距離衰減**（σ = 80 km，EPSG:3826）。產物見 `fyp_taiwan_spatial_gnn/rq2_county/`；協定見 `rq2_county_protocol.json`。**鄉鎮層圖實驗屬補充線，其 MAE 不併入本節與家族 A。**

表 11　RQ2 縣市 DPP 平均 OOT MAE（2012–2024；節錄）

模型	鄰接	Mean MAE	Mean RMSE
PreviousShare	**none**	**0.0793**	**0.0814**
SGC_L2+RandomForest	dist_decay_bin	0.1029	0.1152
SGC_L1+RandomForest	dist_decay_bin	0.1033	0.1154
SGC_L1+RandomForest	queen	0.1037	0.1152
SGC_L2+RandomForest	queen	0.1040	0.1156
NonSpatial RandomForest	**none**	**0.1043**	**0.1163**
NonSpatial HistGradientBoosting	none	0.1189	0.1268
ResidualGCN_L2	knn	0.1289	0.1317
ResidualGCN_L2	dist_decay	0.1328	0.1357
TrainableGAT	queen	0.1496	0.1764
NonSpatial Ridge	none	0.1786	0.1855

資料：`fyp_taiwan_spatial_gnn/rq2_county/rq2_county_mean_mae_dpp.csv`。完整表另含其他 SGC／GCN 組合；KMT 目標見 `rq2_county_mean_mae_kmt.csv`（PreviousShare 0.1094 仍最好）。

跨四屆平均，**PreviousShare（0.0793）仍然最好**，空間實驗**不改變**家族 A 的主結論。在學習模型內部，最佳的 SGC_L2+RF（dist_decay_bin，0.1029）僅比 NonSpatial RF（0.1043）低約 **0.0015**——有微弱的空間訊號，但幅度細，不宜誇大。可訓練 ResidualGCN／GAT 的平均誤差（0.129–0.150）明顯差過 NonSpatial RF 與 SGC。

表 12　RQ2 逐年 DPP：PreviousShare vs NonSpatial RF vs 該年最佳空間（事後挑選）

測試年	PreviousShare	RF NonSpatial	該年最佳空間 MAE	最佳空間模型
2012	0.0402	0.0743	0.0233	ResidualGCN_L2 / knn
2016	0.0979	0.1322	0.0552	TrainableGCN_L2 / dist_decay
2020	0.0193	0.0460	0.0428	SGC_L1+RF / dist_decay_bin
2024	0.1596	0.1647	0.1526	ResidualGCN_L2 / dist_decay

資料：`rq2_county_year_comparison_dpp.csv`。「該年最佳空間」是在多種鄰接與架構中事後挑選，**不可**解讀為可事先選到的方法；僅用來說明單年可以看起來很好。

圖 14(b) 改以**固定**模型／鄰接組合畫逐年 MAE，避免事後挑選。可見：PreviousShare 在 2020、2024 仍極具競爭力；SGC_L2+RF 與 NonSpatial RF 幾乎重疊；ResidualGCN（knn）在 2012 年誤差極低（0.023），但 2020 年卻升至約 0.224——**單年可以很漂亮，跨年方差很大**。TrainableGAT 同樣不穩定。在 N = 22 縣市、僅四個測試屆的設定下，圖模型自由度高，容易對個別年份過擬合。

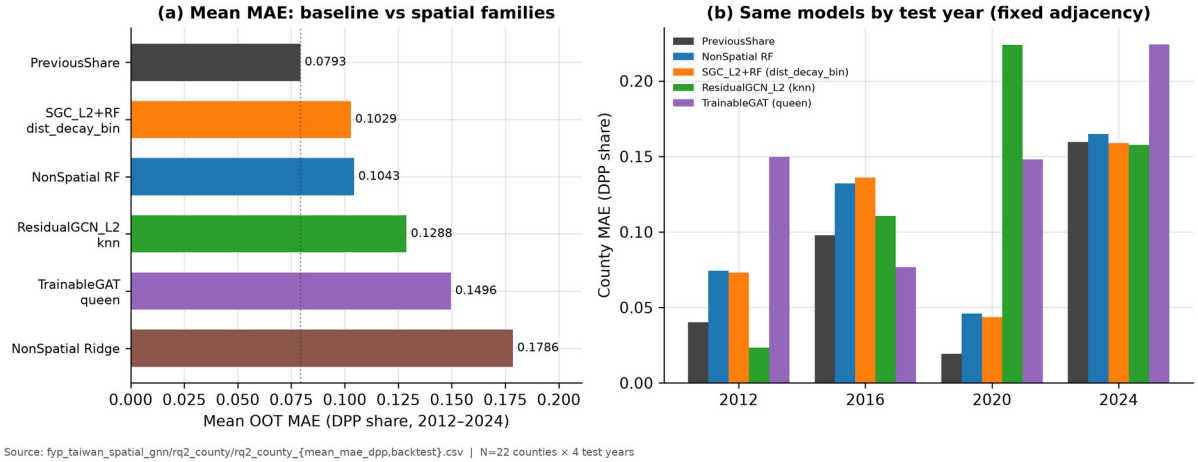


圖 14　縣市空間 RQ2（Guide RQ2）。(a) 2012–2024 平均 MAE：PreviousShare（0.0793）最佳；最佳 SGC+RF（0.1029）僅略優於 NonSpatial RF（0.1043，$\Delta \approx 0.0015$）；ResidualGCN／GAT 更差。(b) 固定模型逐年 MAE（非事後挑選）：SGC 與 NonSpatial RF 接近，可訓練 GNN 波動大。資料：`rq2_county_mean_mae_dpp.csv`、`rq2_county_backtest.csv`。

誠實結論：（1）Headline 對齊家族 A——PreviousShare 仍最好；（2）SGC 相對 NonSpatial 有約 0.0015 的微弱增益，不足以改寫主故事；（3）可訓練 GCN／GAT／ResidualGCN 已跑通並有 ablation，但**不建議當主結果**；（4）Queen 真共邊與 dist-decay／k-NN 結果接近，離島需靠後兩者補邊；（5）本節不主張空間依賴的因果外溢——只報告 OOT 預測誤差。

6　討論

6.1　穩定的地理、會擺盪的全國

綜合以上結果，可以把台灣縣市總統得票拆成兩個部分來理解：一是**相對穩定的地理結構**（哪些縣市比全國更綠或更藍），二是**每屆的全國擺盪**。上屆結果幾乎完整保存了前者，因此成為強基準，也是學習模型唯一真正依賴的訊號（5.1–5.2 節）；但它對後者無能為力，所以在 2016 與 2024 這類大擺盪年誤差最大。全國選前民調正好提供了後者的當屆訊息，UniformPollSwing 把兩部分直接相加，便把平均誤差從 0.0793 降到 0.0266。

6.2 簡單模型為何勝出

在四個測試屆的極小樣本下，模型的「歸納偏誤」比「彈性」重要。UniformPollSwing 把正確的結構（地理 + 全國擺盪）寫死在公式中，不需要從資料中學習；Ridge、RF、HGB 則必須從 22–88 列中估計這些關係，因而容易受單一屆的特殊情況影響。這並不代表機器學習沒有價值，而是提醒我們：在資料極稀疏的政治預測場景，**應先證明能贏過結構化的簡單基準，再談複雜模型**。5.5 節的擬合分析更直接地說明這一點：擬合出的擺盪權重 $c \approx 0.75$ 在樣本內更貼近資料，但在時間外推下 MAE 由 0.0266 升至 0.0575；樣本內 R^2 高達 0.986 的 History+Poll OLS，其對應的 OOT 誤差也遠高於無參數方法。

6.3 資料品質是方法的一部分

2020 年日期修正（5.4 節）說明，資料清理的決定會直接改變研究結論的數字。本研究保留修正紀錄、剔除清單與抽樣檢查文件，使每一個數字都可追溯。對學術研究而言，這種可稽核性與模型選擇同樣重要。

6.4 本研究不主張什麼

- **不主張勝選機率**：本研究評估的是縣市得票份額 MAE，而非誰會當選；區間預測尚未校準。
- **不主張因果**：permutation importance 只描述模型在回測中的依賴；政綱消融結果不能解讀為「某議題影響投票」。
- **不把民調當作模型準確度的標準**：民調測量的是候選人意向，模型目標是政黨有效票份額，兩者估計量不同。

6.5 空間模型放在哪裡

縣市空間 RQ2 的角色是**對照實驗，不是新的主結果**。它回答的是「在已證明很難打的 PreviousShare 基準旁邊，圖擴散與可訓練 GNN 能不能穩定加分」。答案是：幾乎不能——SGC+RF 的平均增益約 0.0015，可訓練網路更不穩。這與 5.1–5.2 節「地理結構已被上屆結果吸收」一致：鄰縣資訊若主要重複了 `prev` 所含的空間相關，就難再榨出預測力。因此本文把空間線定位為 Guide RQ2 的完成項與微弱／負面結果，**不**與家族 A 或 UniformPollSwing 混報為同一貢獻。

7 研究限制與未來工作

7.1 研究限制

6. **測試屆極少**：完整可比的 OOT 窗口只有 2012–2024 四屆（88 個縣市×年份）；同屆縣市共享候選人與全國事件，不能視為 88 個獨立樣本，任何平均改善都帶有很大的抽樣不確定性。
7. **只有全國層級民調**：沒有可稽核的縣市民調；UniformPollSwing 假設各縣市擺盪相同，無法捕捉地區差異。2004 年僅 8 筆民調且多為二次引用；2024 年 60 日窗內 40 筆中只有 10 筆通過候選人配對。
8. **不確定性未校準**：既有 conformal 區間實驗的經驗覆蓋率約僅 2.9%–13.6%，遠低於標稱水準（如 90%），因此本文不以預測區間作為貢獻。
9. **TEDS 尚未整合**：選前調查資料需研究者本人於 TEDS／SRDA 註冊申請，目前僅完成申請途徑與題目對照。
10. **政綱來源未覆核**：多為新聞整理、維基百科或 OCR，`verified` 欄空白；總統公報本身不刊政見；各屆覆蓋不均，2004 年選前列為零。
11. **2004／2008 可比性**：History 系列模型在這兩屆無值，圖中以陰影標示，不宜與 2012 年後的序列直接比較。
12. **縣市空間 RQ2 已完成但增益有限**：SGC+RF 僅略勝 NonSpatial RF（$\Delta \approx 0.0015$）；可訓練 GCN／GAT 跨年不穩；N=22、離島 Queen 無邊、測試屆僅四屆。空間結果為對照，不取代家族 A。
13. **跨國（美台）遷移屬延伸**：美台聯合模型與領域適應屬 Extension，不與家族 A／RQ2 混報。
14. **重現性仍待加強**：核心回測已於同一環境重現至浮點精度，但乾淨環境重跑與版本控制（Git remote）仍待完成。

7.2 未來工作

- 取得授權後納入 **TEDS 選前波次**，以權重聚合為全國或分區特徵，並嚴格維持選前切割。
- 蒐集**縣市或分區民調**，檢驗 UniformPollSwing 的空間異質性，例如比例擺盪或依縣市傾向調整的擺盪。
- 改善民調特徵：處理 2024 年候選人名稱配對、機構效應與樣本數加權。
- 以候選人官方白皮書等一**手政見全文**重建政綱長表並人工覆核，再以同一窗口重跑消融。

- 依訓練／校準／測試年分開的設計重做 conformal 區間，回報經驗覆蓋率與區間寬度；未達標則維持為附錄。
- 縣市 RQ2 已完成；後續可嘗試 GraphSAGE／人口流動邊權或更深 GPU 圖網，但仍須對照 PreviousShare。美台跨國遷移屬 Extension。

8 結論

本研究以 2000–2024 年台灣總統選舉 22 縣市資料，建立嚴格的時間外推回測，回答了四個研究問題。**RQ1**：純歷史特徵的學習模型無法勝過上屆基準（0.0793 vs. 0.104–0.178）。**RQ2**：這些模型 92.6%–100% 依賴上屆結果，並未學到更強的結構。**RQ3**：加入全國選前民調後，最簡單的 UniformPollSwing 將平均誤差降至 0.0266，四屆中有三屆勝過基準（2020 年基準 0.0193 較佳）；History+Poll Ridge 為 0.0611。權重分析顯示，縣市在描述上約跟隨全國民調擺盪的四分之三（c = 0.747），但擬合權重在時間外推下過度擬合（0.0575），固定權重 1 最穩健。**RQ4**：現有政綱特徵不穩定，也無法在民調之上帶來增益。**RQ5／Guide RQ2**：縣市空間模型未改寫基準故事 —— PreviousShare 0.0793 仍最好，SGC+RF 僅略勝 NonSpatial RF（Δ ≈ 0.0015），可訓練 GNN 不穩定。

故事的核心可以濃縮成一句話：**台灣的政治地理很穩定，難的是全國擺盪；選前民調恰好告訴我們擺盪的方向與大小，而空間圖模型幾乎加不了分**。同時，2020 年日期錯誤的插曲提醒我們，可稽核的資料清理與誠實報告較差但可信的數字，是讓這個結論站得住腳的前提。所有結論均應附帶「四個測試屆、全國層級民調、政綱未覆核、區間未校準」的限定條件。

參考資料

[1] 中央選舉委員會（CEC）選舉資料庫（政府資料開放平台 dataset 13119）：https://data.gov.tw/dataset/13119

[2] 國立政治大學選舉研究中心，歷屆總統選舉縣市得票表（2000／2004／2008）：https://vote.nccu.edu.tw/cec/A2000005.PDF、A2004005.PDF、A2008005.PDF

[3] 台灣選舉與民主化調查（TEDS）：https://teds.nccu.edu.tw/ ；SRDA：https://srda.sinica.edu.tw/

[4] Chen, Lu-Huei (2025). TEDS2024-T (D00257). SRDA. https://doi.org/10.6141/TW-SRDA-D00257-1

[5] 維基百科（中文、英文）各屆中華民國總統選舉條目與民調表格（例：https://zh.wikipedia.org/zh-tw/2000 年中華民國總統選舉）

[6] TVBS 新聞（2004 選前民調）：https://news.tvbs.com.tw/life/380727；VOA、CCTV 二次引用（見 `docs/taiwan_polls_2004_sources.md`）

[7] 風傳媒（2020-01-09 選前政見整理）：https://www.storm.mg/article/2159574；中央社：https://www.cna.com.tw/news/firstnews/201911230166.aspx

[8] 〈面板模型與經濟投票〉，中研院人社中心期刊 PDF：https://www.rchss.sinica.edu.tw/files_news/21-03-2009/cc2133.pdf（作者、年份、卷期待補）[citation needed]

[9] 〈政治版圖與空間分析〉，中研院人社中心期刊 PDF：https://www.rchss.sinica.edu.tw/files_news/24-02-2012/1.pdf（作者、年份、卷期待補）[citation needed]

[10] 〈台灣總統選舉的分類與迴歸樹預測分析：以 2012 年與 2016 年總統選舉為例〉，臺灣博碩士論文知識加值系統（書目資料待補）[citation needed]

[11] Gibbs, I., & Candès, E. (2021). Adaptive Conformal Inference Under Distribution Shift. NeurIPS 2021（專案 `methodology.md` 記為 ICLR 2021，請以原始出處核對）。

附錄 A　重現性：腳本、路徑與指令

專案根目錄為筆電上的 `FYP TW/`（OneDrive 桌面）；子專案為 `FYP TW/tw-election-forecast/`。環境：Python 3.13.5、pandas 2.3.2、NumPy 2.3.3、scikit-learn 1.7.2、SciPy 1.16.2、Matplotlib 3.10.6（`REPRODUCIBILITY.md`）。

表 13　主要腳本與輸出

步驟	腳本	主要輸出
核心回測（家族 A）	tw-election-forecast/scripts/taiwan_core_backtest.py	tw-election-forecast/analysis/taiwan_core/backtest_metrics.csv、summary.json
民調爬取	scripts/scrape_taiwan_polls_wikipedia.py	inputs/taiwan_polls.csv
民調日期修正	scripts/fix_taiwan_poll_dates.py	outputs/metrics/taiwan_polls_date_corrections.csv、taiwan_polls_dropped_undateable.csv
民調驗證正規化	src/prepare_taiwan_polls.py	outputs/metrics/taiwan_polls_long.csv、taiwan_polls_summary.json
民調消融	scripts/run_taiwan_poll_ablation.py	outputs/metrics/taiwan_poll_ablation_metrics.csv
政綱爬取	scripts/scrape_taiwan_platforms_wikipedia.py	inputs/taiwan_platforms_long.csv
政綱消融	scripts/run_taiwan_platform_ablation.py	outputs/metrics/taiwan_platform_ablation_metrics.csv、taiwan_platform_year_features.csv、taiwan_platform_ablation_summary.json
鄉鎮 permutation importance	src/township_permutation_importance.py	outputs/metrics/township_v0/township_permutation_importance*.csv
特徵權重與擬合	scripts/fit_feature_weights.py	outputs/metrics/feature_weights_*.csv、feature_weights_summary.json；outputs/figures/feature_weights_*.png
核心圖	scripts/plot_core_mae_figures.py	outputs/figures/core_mae_by_year.png、core_mae_mean_2012_2024.png
本報告圖表	docs/report_figures/make_report_figures.py（本報告新增）	docs/report_figures/fig_*.png
本報告文件	docs/report_figures/build_report_docx.py（本報告新增）	docs/TW_Election_Forecast_FYP_Report.docx／.pdf

建議重跑順序（於 `FYP TW/` 根目錄，PowerShell）：

```
python scripts\fix_taiwan_poll_dates.py
python src\prepare_taiwan_polls.py
python scripts\run_taiwan_poll_ablation.py
python scripts\run_taiwan_platform_ablation.py
python src\township_permutation_importance.py
python scripts\plot_core_mae_figures.py
python tw-election-forecast\scripts\taiwan_core_backtest.py
```

附錄 B　數字版本對照與圖表資料來源

專案中有兩條產生 History 系列 MAE 的管線，數字在小數第三位略有差異，本文主結果以消融管線為準（因民調與政綱實驗皆在其中完成），並以家族 A 作為獨立重現：

表 14　兩條管線的四屆平均 MAE 對照

模型	消融管線（14 特徵）	家族 A 核心回測（16 特徵）
PreviousElectionBaseline	0.0793	0.0793
Ridge	0.1776	0.1786
Random Forest	0.1041	0.1040
HistGradientBoosting	0.1257	0.1189

資料：`taiwan_poll_ablation_metrics.csv`；`tw-election-forecast/analysis/taiwan_core/summary.json`。

表 15　圖表與資料來源

圖	內容	資料檔
圖 1	政治地理穩定性	data/county_panel_features_2000_2024.csv
圖 2	資料覆蓋	taiwan_polls_long.csv；taiwan_platforms_long.csv
圖 3	研究管線	（示意圖）
圖 4	基準 vs History 模型	taiwan_poll_ablation_metrics.csv
圖 5	鄉鎮 permutation importance	township_v0/township_permutation_importance{,_mae}.csv
圖 6–7	核心 MAE 圖	outputs/figures/core_mae_*.png（既有）
圖 8	民調擺盪	taiwan_polls_long.csv（重新計算）；taiwan_poll_ablation_metrics.csv
圖 9	日期修正教訓	RESULTS_DRAFT.md；taiwan_polls_date_corrections.csv
圖 10	History+Poll OLS 係數	feature_weights_key_coefs.csv（既有圖）
圖 11	樣本內診斷	feature_weights_residuals.csv（既有圖合併）
圖 12	樣本內 vs OOT	feature_weights_fit_quality.csv（既有圖）
圖 13	政綱消融	taiwan_platform_ablation_metrics.csv
圖 14–15	RF permutation／Ridge 標準化係數	feature_weights_permutation_importance.csv；feature_weights_ridge_standardized.csv（既有圖）

所有新圖以 matplotlib 產生，300 dpi，英文軸標籤；腳本為 `docs/report_figures/make_report_figures.py`（腳本內輸入路徑為製作時的工作目錄，於筆電重跑時請將 `S／OUT` 改為專案根目錄與 `docs/report_figures/`）。

附錄 C　其他特徵權重視角

以下兩張圖提供 5.5 節以外的權重視角，同樣只代表模型在合併面板上的預測依賴，不具因果意義（`docs/feature_weights.md`）。

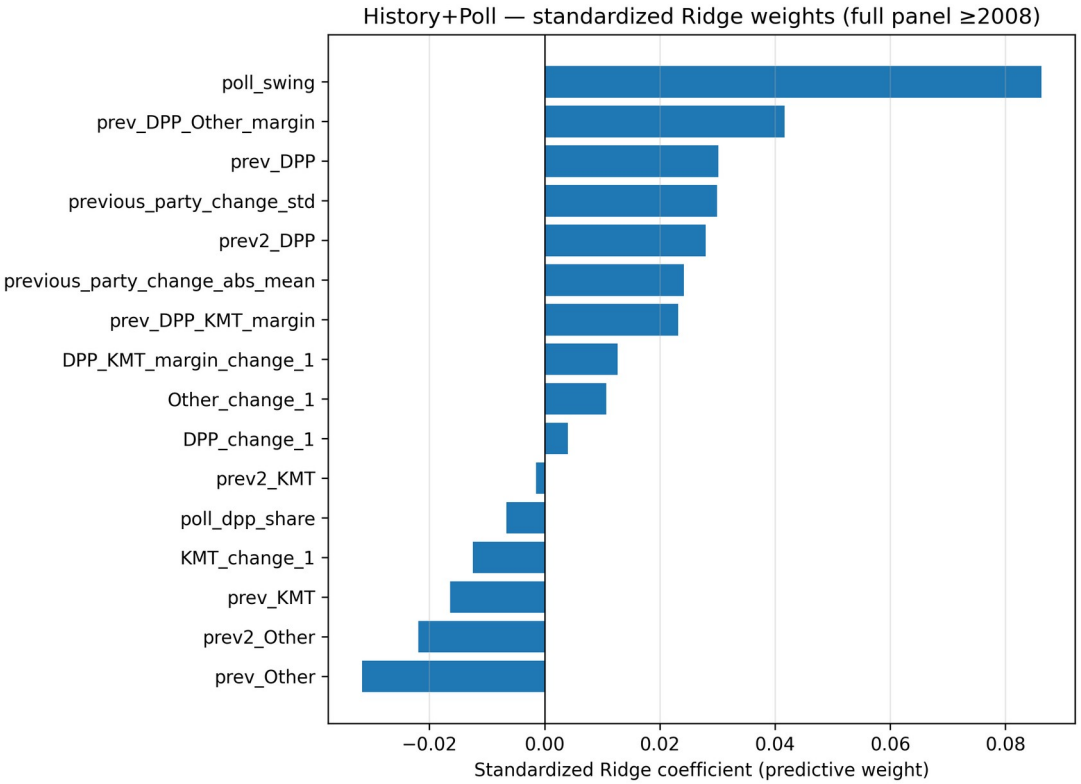


圖 15　標準化 Ridge（α = 1）係數，History+Poll。絕對值最大者為 `poll_swing`（+0.086），其次為 `prev_DPP_Other_margin`（+0.042）、`prev_Other`（−0.032）、`prev_DPP`（+0.030）。標準化後的排序比 OLS 原始係數更適合描述相對權重。資料：`outputs/metrics/feature_weights_ridge_standardized.csv`。

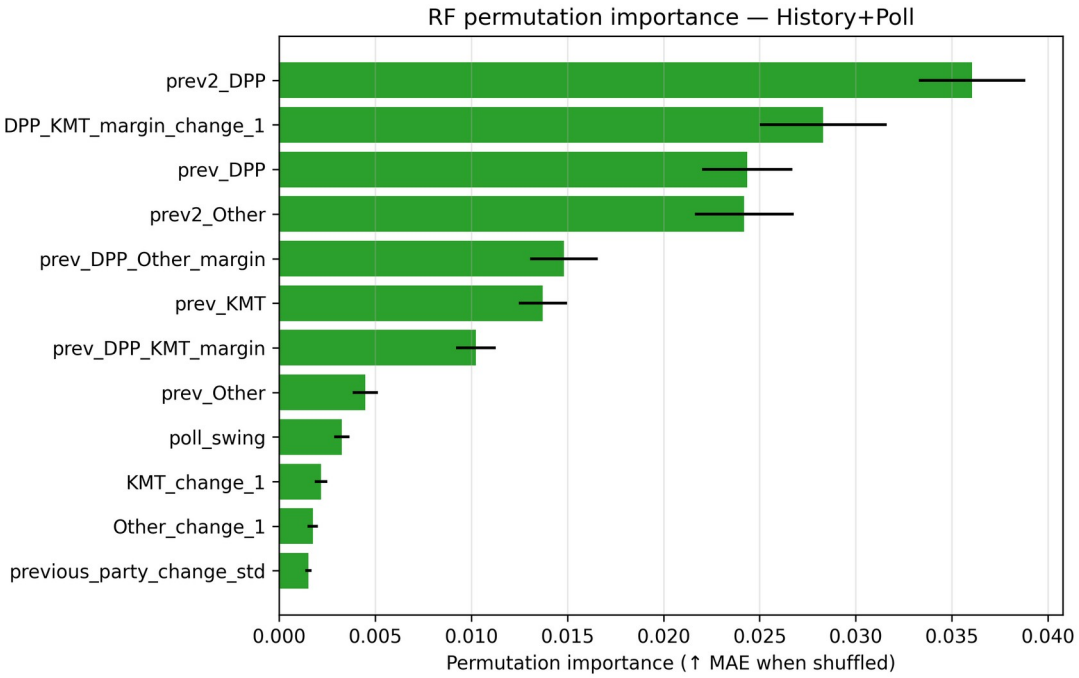


圖 16 Random Forest permutation importance（MAE 增加量），History+Poll。RF 最依賴 `prev2_DPP`、`DPP_KMT_margin_change_1`、`prev_DPP` 與 `prev2_Other`，民調特徵排名較低（`poll_swing` 約 0.003）；HGB 對 `poll_swing` 的依賴略高（約 0.009）。這與 5.3 節中樹模型加入民調後幾乎沒有改善的結果一致。資料：`outputs/metrics/feature_weights_permutation_importance.csv`。